Pemodelan Multi-Output Transisi Energi Permukiman Perkotaan

Ahnaf Sega Linambaran Faradha Jocelyn Louisa

ahnafsega39@gmail.com nambafq042@gmail.com

jocelynlouisa22@gmail.com

Abstrak

Penelitian ini mengembangkan alur prediksi untuk lima indikator transisi energi permukiman pada kompetisi DICE FEST 2026: konsumsi gas, konsumsi listrik, intensitas gas per luas bangunan, proporsi bangunan hijau, dan adopsi pemanas listrik. Dataset berisi 429.303 observasi latih dan 183.987 observasi uji, dengan fitur bangunan, iklim, dan sosiodemografi yang dianonimkan. Eksplorasi menemukan hubungan kuat antara ukuran bangunan dan kebutuhan energi makro, variasi antarkawasan, serta dua hubungan deterministik antarkolom. Kami membentuk rasio berbasis luas dan agregasi wilayah, kemudian melatih XGBoost dan multilayer perceptron (MLP) untuk tiga target energi. Prediksinya digabung melalui *non-negative least squares*; rasio bangunan hijau dihitung menggunakan formula yang tepat pada seluruh data latih; sementara adopsi pemanas listrik menggunakan *subzone lookup* dan model residual untuk subzone yang belum dikenal. Dengan lima target berbobot sama, *out-of-fold* (OOF) NRMSE akhir mencapai **0,255007**. Audit spasial terpisah dengan GroupKFold memberikan NRMSE **0,28139** untuk baseline, menandakan bahwa perpindahan kawasan tetap perlu diwaspadai. Interpretasi *feature importance* menunjukkan bahwa informasi regional, dimensi bangunan, dan rasio geometris berpengaruh pada komponen XGBoost, tetapi tidak dapat ditafsirkan sebagai hubungan kausal. Rekomendasi kebijakan difokuskan pada prioritas audit efisiensi bangunan, perencanaan kapasitas listrik, dan penanganan kesenjangan adopsi teknologi pemanas.

Kata kunci: konsumsi energi bangunan; multi-output regression; feature engineering spasial; XGBoost; MLP; NRMSE.

BAB I — Pendahuluan dan Pemahaman Studi Kasus

Latar belakang

Sektor bangunan menghadapi dua tuntutan yang berjalan bersamaan: menurunkan ketergantungan pada energi fosil dan tetap menyediakan layanan energi yang terjangkau. Upaya mengurangi penggunaan gas tidak otomatis mengurangi tekanan pada sistem energi secara keseluruhan. Pemanas listrik, misalnya, dapat mengalihkan kebutuhan energi dari jaringan gas ke jaringan listrik. Di sisi lain, efisiensi termal bangunan menentukan besarnya energi yang diperlukan untuk mencapai kenyamanan yang sama. Laporan IPCC menempatkan efisiensi dan elektrifikasi bangunan sebagai bagian dari mitigasi emisi, dengan hasil yang bergantung pada karakteristik stok bangunan serta pasokan energi [2, 3].

Kompetisi DICE FEST 2026 memformulasikan persoalan tersebut sebagai *The Urban Energy Transition Trilemma* [1]. Tiga persoalan yang perlu dibaca bersama ialah (1) besarnya

konsumsi gas total versus intensitas konsumsi per meter persegi, (2) pengurangan gas melalui elektrifikasi versus tambahan permintaan listrik, dan (3) potensi renovasi bangunan versus hambatan insentif menurut kondisi hunian dan kepemilikan. Penelitian berbasis model energi perkotaan juga menunjukkan pentingnya kombinasi geometri, kondisi bangunan, dan keragaman kawasan dalam menjelaskan konsumsi energi [4, 5].

Rumusan masalah dan tujuan

Tujuan pekerjaan ini ialah membangun prediksi lima target dari fitur yang tersedia tanpa menambah data eksternal atau melakukan pelabelan manual. Secara teknis, tugas disusun sebagai lima masalah regresi yang saling berkaitan. Strategi pemodelan tidak harus sama untuk setiap target karena struktur statistiknya berbeda. Sebagai contoh, konsumsi energi makro dipengaruhi skala bangunan, sedangkan rasio bangunan hijau ternyata dapat direkonstruksi secara deterministik dari dua kolom fitur.

Hasil model diarahkan untuk membantu penentuan prioritas inspeksi, bukan langsung menetapkan kebijakan otomatis. Identitas geografis telah dianonimkan; karena itu hasil tidak digunakan untuk menunjuk kecamatan tertentu atau mengklaim dampak kausal kebijakan.

BAB II — Eksplorasi Data dan Rekayasa Fitur Domain

Struktur data dan pemeriksaan kualitas

Data latih memiliki 429.303 baris dan 209 kolom; data uji memiliki 183.987 baris dan 204 kolom. Kelima kolom selisih tersebut merupakan target yang tidak tersedia pada data uji. Identitas spasial terdiri atas `zone_region_id` dan `subzone_id`; fitur lain mencakup kelompok `bld_dim`, `bld_era`, `hvac_dist`, `env_climate`, dan `socio_demog` [1]. Seluruh 330 region pada data latih tercakup di data uji, sedangkan 14.979 baris data uji (8,14%) berada pada subzone yang tidak muncul pada data latih.

Nilai hilang hanya terdapat pada `bld_dim_04` dan `bld_dim_07`, masing-masing 695 baris latih dan 336 baris uji. Keduanya hilang pada baris yang sama. Tidak terdapat target hilang. Fitur konstan atau tanpa variasi dikeluarkan saat membentuk matriks model. Untuk model pohon, nilai yang tidak diketahui dipertahankan sebagai *NaN*; pada model yang membutuhkan matriks numerik terisi, imputasi dan normalisasi dihitung dari partisi latih. Dengan demikian, statistik label dari fold validasi tidak dipakai untuk memproses pelatihan.

Table 1: Statistik lima target pada data latih. Seluruh angka berasal dari keluaran notebook.

Target	Rerata	Simpangan baku	Skewness	Median
Gas makro (kWh)	230.372,43	151.750,04	1,218	193.549,48
Listrik makro (kWh)	63.755,90	41.725,37	1,227	53.838,93
Gas EUI (kWh/m^2)	139,06	40,65	1,298	134,85
Rasio bangunan hijau (%)	90,76	12,49	$-1,569$	96,30
Adopsi pemanas listrik (%)	5,38	7,18	3,403	3,10

Sebanyak 46,12% observasi memiliki rasio bangunan hijau tepat 100%, sedangkan 7,89% bernilai nol pada adopsi pemanas listrik. Distribusi berpenumpukan batas ini menjadi alasan untuk membatasi prediksi persentase pada interval 0–100. Untuk gas dan listrik, kemencengan ke kanan menunjukkan bahwa galat di beberapa observasi berukuran besar berpotensi

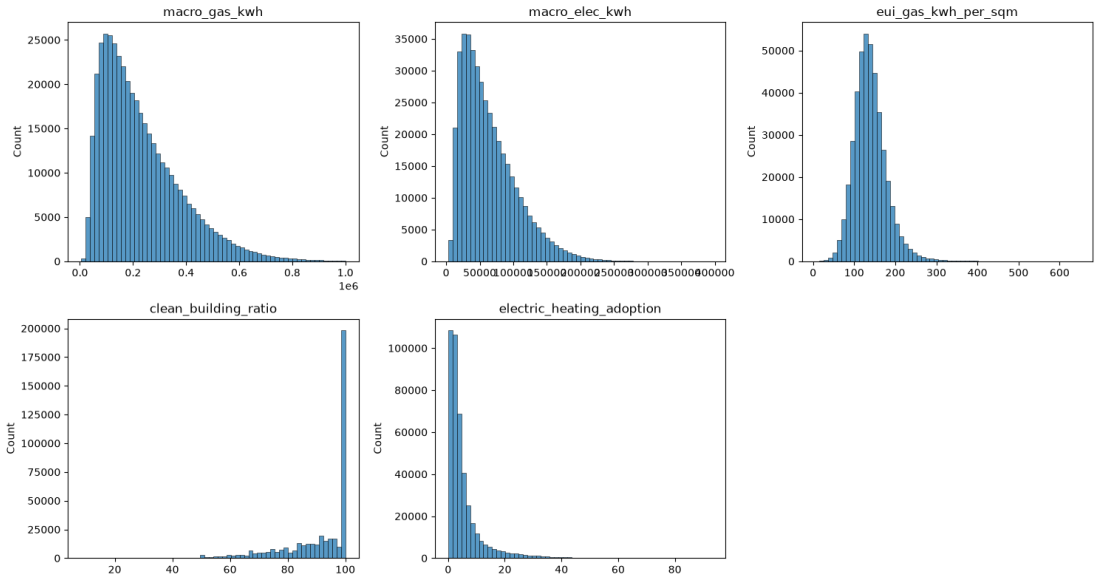


Figure 1: Distribusi lima target. Skala gas dan listrik jauh lebih besar daripada tiga target lainnya; rasio bangunan hijau terkonsentrasi di batas 100%.

memengaruhi RMSE secara kuat.

Keterkaitan target, ukuran, dan kawasan

Korelasi Pearson antara `bld_dim_06` dan gas makro mencapai 0,899; untuk listrik makro, `bld_dim_12` memiliki korelasi 0,882. Hubungan linear fitur tunggal dengan gas EUI jauh lebih kecil; korelasi absolut terbesarnya pada pemeriksaan awal hanya sekitar 0,194. Angka tersebut menjelaskan mengapa pendekatan berbasis dimensi saja lebih mudah untuk konsumsi total daripada intensitas per luas.

Observasi dikelompokkan ke dalam 330 region dengan jumlah baris per region yang tidak seimbang (median 1.021,5; rentang 4–7.072). Proporsi variasi target yang dapat dikaitkan dengan perbedaan rerata region, diukur dengan η^2, paling besar untuk rasio bangunan hijau (0,1734) dan gas EUI (0,1251). Nilai tersebut tidak berarti identitas region menjelaskan seluruh perbedaan, tetapi cukup untuk menjadi alasan melakukan audit validasi spasial.

Pemeriksaan *Kolmogorov–Smirnov* pada sampel 30.000 baris dari masing-masing set menunjukkan perbedaan kecil untuk fitur utama; nilai statistik KS untuk `bld_dim_06`, `bld_dim_12`, dan `hvac_dist_02` masing-masing sekitar 0,006; 0,004; dan 0,006. Karena statistik ini dihitung dari sampel, temuan tersebut menunjukkan kemiripan distribusi secara umum dan bukan jaminan bahwa data uji identik dengan data latih.

Rekayasa fitur fisik dan spasial

Rekayasa fitur disusun dari data kompetisi saja. Tiga kelompok transformasi yang digunakan ialah sebagai berikut.

1. **Rasio fisik dan normalisasi luas.** Untuk fitur geometri atau demografi terpilih dibentuk x_j/A, dengan A adalah `bld_dim_06` yang digunakan sebagai proksi luas positif. Rasio pasangan fitur, misalnya `bld_dim_12`/`bld_dim_03`, serta selisih *log1p* dibentuk untuk menangkap hubungan relatif yang tidak terwakili nilai absolut.

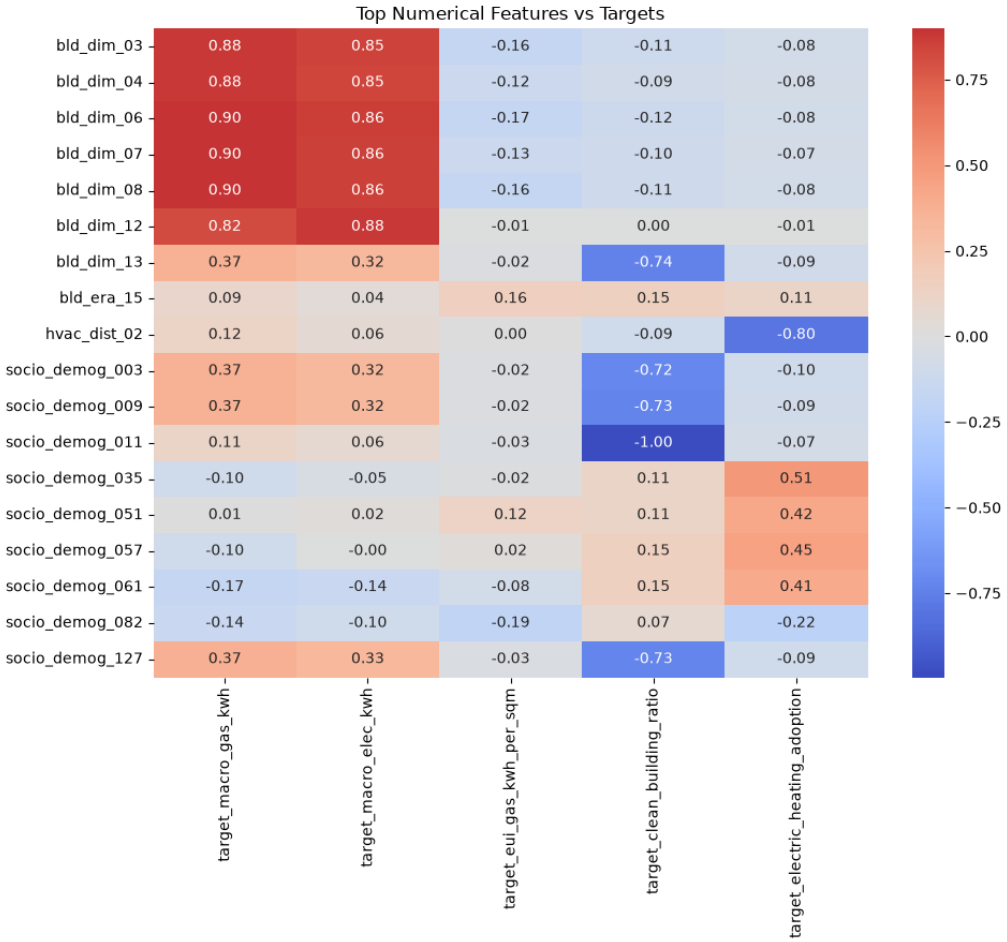


Figure 2: Korelasi fitur numerik terpilih dengan lima target. Besaran korelasi tidak digunakan sebagai bukti sebab-akibat.

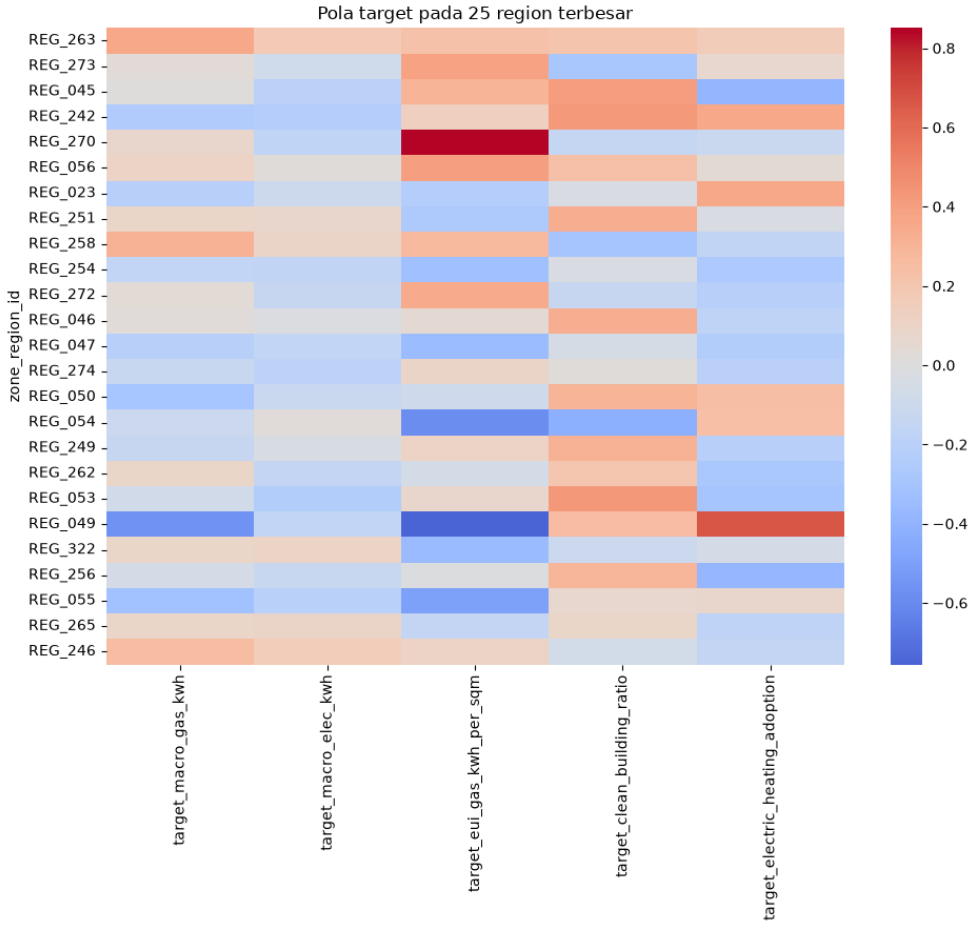


Figure 3: Rerata target terstandardisasi pada 25 region dengan jumlah observasi terbanyak. Kode region merupakan pengenal anonim.

2. **Agregasi kawasan.** Rerata beberapa variabel geometri dan iklim dihitung per region; rerata fitur geometri dihitung pula per subzone. Fitur lain mencakup jumlah observasi per kawasan, posisi relatif luas bangunan terhadap rerata region, serta peringkat luas dalam region.

3. **Target encoding aman terhadap label validasi.** Untuk setiap fold, ringkasan target berdasarkan region dan subzone dihitung dari bagian latih saja, dengan penghalusan menuju rerata global. Nilai pada baris latih dihasilkan melalui lima fold internal (*inner OOF*); label validasi luar tidak ikut menghitung encoding-nya.

$$\mathrm{TE}(g) = \frac{\sum_{i \in g} y_i + \alpha \bar{y}}{n_g + \alpha}, \tag{1}$$

dengan g kelompok spasial, n_g ukuran kelompok pada data latih yang diizinkan, $\bar{y}$ rerata target bagian latih, dan α parameter penghalusan. Nilai α pada notebook adalah 10 untuk region dan 2 untuk subzone. Setelah rekayasa fitur, tersedia 457 kolom kandidat; 340 fitur dasar dipertahankan untuk jalur model pohon, kemudian ditambahkan 10 fitur target encoding sesuai fold.

Pemeriksaan hubungan deterministik

Kedua hubungan berikut diuji pada seluruh data latih:

$$\text{clean ratio} = \mathrm{clip}\left(\mathrm{round}\left(100\frac{\text{bld_dim_02}}{\text{bld_dim_01}}, 2\right), 0, 100\right), \tag{2}$$

$$\text{gas makro} = \text{gas EUI} \times \text{bld_dim_06}. \tag{3}$$

Formula rasio bangunan hijau cocok tepat pada 100% baris data latih, dengan galat maksimum nol. Identitas gas–EUI juga cocok secara numerik hingga galat absolut maksimum sekitar $4,66 \times 10^{-10}$ kWh. Hubungan ini digunakan sebagai kendala konsistensi dan calon prediksi lintas-target; tidak ditafsirkan sebagai penemuan baru mengenai perilaku energi. Sebutan geometri atau luas mengikuti peran fitur di dalam dataset dan belum dapat diverifikasi sebagai ukuran bangunan fisik tertentu karena anonimisasi.

BAB III — Arsitektur Model Multi-Output dan Validasi Spasial

Strategi pemodelan

Kami tidak memaksa lima target mengikuti satu regressor tunggal. Gas makro, listrik makro, dan gas EUI dipelajari melalui beberapa kandidat XGBoost dan MLP. Untuk gas dan listrik, selain target asli, kami melatih regresi dalam skala per luas: y/A. Prediksi per luas dikalikan kembali dengan A sehingga hasil akhir tetap memakai satuan target resmi. Pendekatan ganda ini menyeimbangkan informasi skala bangunan dan intensitas energi.

XGBoost dipilih karena dapat memodelkan relasi nonlinier dan menerima fitur dengan nilai hilang. MLP dipakai sebagai pembanding yang memiliki struktur fungsi berbeda; masukan numerik dinormalisasi di dalam tiap fold. Keragaman keluaran kedua jenis model dimanfaatkan melalui *stacking* [6, 7]. Bobot ensemble dihitung dengan *non-negative least squares* (NNLS),

yaitu meminimalkan kuadrat galat di bawah kendala bobot tidak negatif. Kandidat lintas-target dari hubungan gas = EUI × luas dimasukkan ke kumpulan prediksi gas dan EUI.

Untuk rasio bangunan hijau, prediksi berasal dari formula yang sudah diverifikasi, bukan model statistik. Untuk adopsi pemanas listrik, subzone yang pernah muncul menggunakan rerata target subzone dari bagian latih. Bagi subzone baru, model Ridge menangkap pola umum fitur pemanas, sosiodemografi, dan iklim; XGBoost kemudian memperkirakan residual Ridge. Cabang ini diperlukan karena terdapat subzone baru pada data uji.

Metrik dan validasi

Sesuai ketentuan kompetisi, setiap target berkontribusi 20% terhadap skor akhir. Untuk target k dengan simpangan baku beku σ_k, metriknya adalah

$$\mathrm{NRMSE}_k = \frac{\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_{ik} - \hat{y}_{ik})^2}}{\sigma_k}, \qquad \mathrm{Score} = \frac{1}{5}\sum_{k=1}^{5}\mathrm{NRMSE}_k. \tag{4}$$

Nilai σ_k resmi berturut-turut adalah 151.750,04; 41.725,37; 40,65; 12,49; dan 7,18. Pengembangan utama menggunakan *random* KFold lima bagian (`SEED`=42) agar seluruh kandidat memiliki pembagian data yang sama. Prediksi validasi dari model dasar dibentuk secara OOF. Bobot NNLS dan pemilihan kandidat kemudian dievaluasi menggunakan pembagian yang ditetapkan pada notebook.

Sebagai audit tambahan, GroupKFold membatasi agar suatu `zone_region_id` hanya berada pada salah satu sisi train atau validasi. Ini relevan ketika observasi dalam kawasan yang sama memiliki ketergantungan spasial [8]. Audit tersebut memakai baseline XGBoost tersendiri dan jalur pemanas berbasis subzone; *bukan* evaluasi langsung ensemble akhir. Agregasi fitur tanpa label dibentuk dari seluruh fitur train–test, sehingga eksperimen ini merupakan evaluasi dengan informasi kovariat gabungan, bukan simulasi ketat ketika informasi wilayah validasi sama sekali tidak tersedia.

Hasil prediksi

Table 2: Perbandingan kandidat dan model final berdasarkan OOF Column-Wise NRMSE (lebih kecil lebih baik).

Target	XGB langsung	XGB per luas	MLP terpilih	Model final
Gas makro	0,25455	0,25296	0,25277	**0,24878**
Listrik makro	0,32382	0,32198	0,32040	**0,31836**
Gas EUI	0,66754	–	0,66799	**0,65718**
Rasio bangunan hijau	–	–	–	**0,00000**
Adopsi pemanas listrik	–	–	–	**0,05072**
			Rerata lima target	**0,255007**

Angka pada Tabel 2 diambil dari output eksekusi notebook gabungan, bukan estimasi ulang. Prediksi gas dan listrik membaik setelah kombinasi model. Untuk EUI, hasil ensemble juga lebih rendah daripada kandidat XGBoost atau MLP secara individual. Keuntungan relatif ini penting karena gas EUI merupakan target yang sulit berdasarkan korelasi linier awal. Nilai rasio bangunan hijau nol berasal dari identitas aljabar yang sudah lolos pemeriksaan pada

seluruh data latih.

Table 3: Audit Spatial GroupKFold pada baseline terpisah; angka tidak setara langsung dengan ensemble OOF final.

Target	Spatial NRMSE
Gas makro	0,26881
Listrik makro	0,32858
Gas EUI	0,69106
Rasio bangunan hijau	0,00000
Adopsi pemanas listrik	0,11850
Rerata baseline spasial	**0,28139**

Perbedaan antara hasil pengembangan dan audit spasial perlu dibaca hati-hati karena arsitektur dan fitur model tidak sepenuhnya sama. Meski demikian, evaluasi pada region yang tidak muncul selama pelatihan mengingatkan bahwa kemampuan generalisasi lintas-kawasan adalah persoalan tersendiri. Secara khusus, NRMSE heating lebih tinggi ketika model tidak dapat mengandalkan lookup subzone yang sudah dikenal.

Notebook menghasilkan berkas submission 183.987 baris dengan enam kolom (ID dan lima target). Tim sebelumnya melaporkan skor Kaggle sekitar 0,252; skor tersebut merupakan catatan eksternal terhadap proses OOF di atas dan tidak digunakan untuk menghitung tabel hasil lokal. Tidak dilakukan penggunaan API prediksi berbayar ataupun injeksi data eksternal.

BAB IV — Analisis Interpretabilitas Model

Metode interpretasi

Bab ini menggunakan *feature importance* komponen XGBoost yang dilatih kembali pada fold validasi pertama. Besarnya importance menunjukkan kontribusi fitur terhadap keputusan pemisahan pohon; grafik tidak menjelaskan keseluruhan ensemble XGBoost–MLP. Penafsiran sengaja dibatasi karena nama fitur bersifat anonim dan korelasi atau importance tidak dapat membuktikan sebab-akibat. Kajian pemodelan energi perkotaan mendukung penggunaan analisis yang dapat dijelaskan, tetapi juga memerlukan pembacaan fisik yang cermat [9, 10].

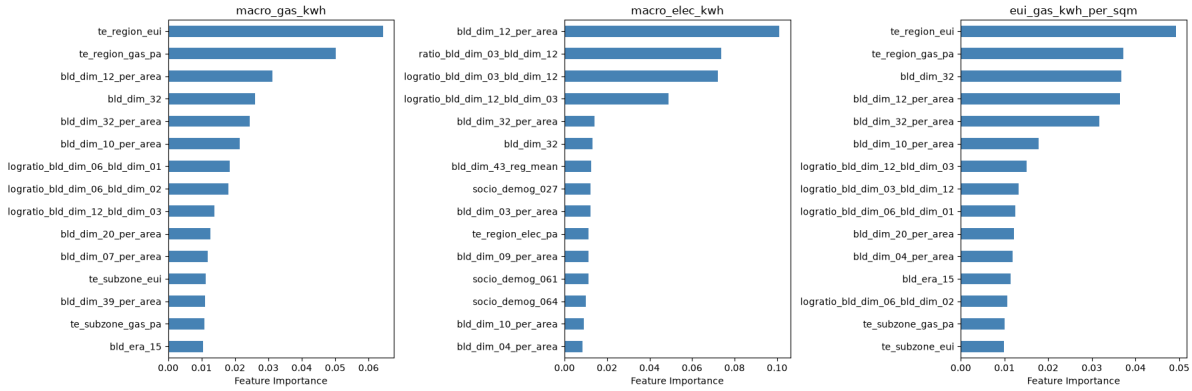


Figure 4: Lima belas fitur teratas menurut importance komponen XGBoost untuk gas, listrik, dan gas EUI. Grafik berasal dari output notebook; bukan importance gabungan seluruh stacking.

Pada komponen gas makro, `te_region_eui` dan `te_region_gas_pa` memiliki importance tinggi, disusul `bld_dim_12_per_area`. Ini menunjukkan model memanfaatkan konteks energi

kawasan dan ukuran relatif bangunan. Pada listrik makro, fitur `bld_dim_12_per_area` serta rasio dan log-rasio pasangan `bld_dim_03` dengan `bld_dim_12` berada pada urutan teratas. Untuk gas EUI, `te_region_eui`, `te_region_gas_pa`, dan `bld_dim_32` menonjol. Dengan demikian, fitur turunan rasio dan ringkasan region bukan hanya penambahan jumlah kolom; beberapa di antaranya benar-benar digunakan oleh salah satu model prediksi akhir.

Namun, importance tinggi pada target encoding tidak bisa diperlakukan sebagai bukti bahwa batas administratif menyebabkan perubahan kebutuhan energi. Target encoding merangkum rata-rata respons lokasi yang sudah diketahui saat pelatihan. Untuk rasio bangunan hijau, penjelasan utamanya justru rumus deterministik; untuk heating, mekanisme paling menentukan adalah apakah suatu subzone pernah teramati. Kedua target tersebut tidak semestinya diberi interpretasi importance XGBoost dari gas/listrik/EUI.

BAB V — Rekomendasi Kebijakan Publik Aksionabel

Prioritas efisiensi termal bangunan

Rangkaian hasil menunjukkan bahwa konsumsi gas total dan gas per meter persegi tidak identik sebagai indikator prioritas. Bangunan besar dapat menyumbang konsumsi makro tinggi walaupun intensitasnya tidak termasuk tertinggi. Pemerintah daerah dapat menjalankan dua daftar prioritas: pertama, kawasan dengan konsumsi gas total prediksi besar untuk estimasi permintaan energi dan potensi pengurangan skala sistem; kedua, bangunan atau subzone dengan prediksi EUI tinggi untuk audit selubung bangunan, kebocoran udara, dan mutu insulasi. Pelaksanaan renovasi tetap membutuhkan verifikasi teknis lapangan sebelum menetapkan intervensi.

Menjaga kesiapan sistem listrik

Kenaikan adopsi pemanas listrik perlu dibandingkan dengan proyeksi permintaan listrik wilayah. Unit utilitas dapat menggabungkan hasil gas, listrik, dan heating untuk menyusun daftar kawasan yang memerlukan pengukuran beban puncak, studi kapasitas trafo, dan penjadwalan peningkatan jaringan. Keluaran model kompetisi berupa konsumsi tahunan, bukan profil beban per jam; karena itu model belum dapat langsung memprediksi overload gardu atau menyimpulkan kapasitas puncak yang diperlukan. Penilaian teknis jaringan listrik tetap harus memakai data beban dengan resolusi waktu yang sesuai.

Mengurangi hambatan adopsi dan renovasi

Kesenjangan adopsi pemanas listrik yang tampak pada data agregat menunjukkan perlunya intervensi yang dibedakan menurut karakter kawasan, bukan satu subsidi seragam. Kajian tentang *split incentive* memperlihatkan bahwa pemilik dan penghuni sewa dapat menghadapi insentif investasi efisiensi yang berbeda [11]. Hasil model dapat digunakan untuk menentukan lokasi survei hambatan investasi dan merancang insentif renovasi bagi pemilik sewa, penghuni, serta pengelola perumahan. Identitas sosiodemografi yang anonim belum cukup untuk menyimpulkan status kepemilikan satu kawasan; verifikasi administratif diperlukan sebelum menyasar program.

Rancangan pemanfaatan yang bertanggung jawab

Sebelum hasil diterapkan, disarankan tiga langkah berurutan. Pertama, cocokkan prediksi dan identitas kawasan dengan data administratif yang sah; kedua, lakukan audit sampel untuk mengukur galat pada wilayah yang berbeda dari data pelatihan; ketiga, gunakan model sebagai alat *screening* dan perbarui estimasi setelah data pemakaian energi dan survei bangunan tersedia. Pendekatan ini membatasi risiko salah sasaran ketika model memanfaatkan hubungan regional yang kuat tetapi tidak selalu stabil pada kawasan baru.

Penutup

Pendekatan yang paling efektif pada data kompetisi bukan satu algoritma yang diterapkan ke seluruh target. Stacking XGBoost–MLP membantu tiga target energi, relasi matematis memungkinkan prediksi tepat rasio bangunan hijau, dan adopsi heating memerlukan perlakuan berbeda bagi subzone lama serta baru. Skor OOF akhir adalah 0,255007. Audit GroupKFold baseline menunjukkan masih ada pekerjaan untuk memastikan ketahanan prediksi lintas-wilayah. Keterbatasan utama penelitian adalah anonimisasi variabel, perbedaan rancangan antara audit spasial dan ensemble final, serta belum tersedianya pengujian kausal kebijakan. Oleh sebab itu, rekomendasi yang dihasilkan bersifat prioritas verifikasi dan perencanaan, bukan klaim dampak emisi yang telah terukur.

Daftar Pustaka

[1] Rohmadi, A. (2026). *DICE FEST 2026 — Machine Learning Competition*. Kaggle. https://www.kaggle.com/competitions/dicefest-2026-machine-learning.

[2] IPCC. (2022). *Climate Change 2022: Mitigation of Climate Change*, Chapter 9: Buildings. Cambridge University Press. https://www.ipcc.ch/report/ar6/wg3/chapter/chapter-9/.

[3] International Energy Agency. (2025). *Energy Efficiency 2025*. IEA, Paris. https://www.iea.org/reports/energy-efficiency-2025.

[4] Reinhart, C. F., & Cerezo Davila, C. (2016). Urban building energy modeling — A review of a nascent field. *Building and Environment*, 97, 196–202. https://doi.org/10.1016/j.buildenv.2015.12.001.

[5] Amasyali, K., & El-Gohary, N. M. (2018). A review of data-driven building energy consumption prediction studies. *Renewable and Sustainable Energy Reviews*, 81, 1192–1205. https://doi.org/10.1016/j.rser.2017.04.095.

[6] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD Conference*, 785–794. https://doi.org/10.1145/2939672.2939785.

[7] Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241–259. https://doi.org/10.1016/S0893-6080(05)80023-1.

[8] Roberts, D. R., et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. https://doi.org/10.1111/ecog.02881.

[9] Li, Z., Ma, J., Jiang, F., Zhang, S., & Tan, Y. (2024). Assessing the impacts of urban morphological factors on urban building energy modeling based on spatial proximity analysis and explainable machine learning. *Journal of Building Engineering*, 85, 108675. https://doi.org/10.1016/j.jobe.2024.108675.

[10] Shams Amiri, S., Mueller, M., & Hoque, S. (2023). Investigating the application of a commercial and residential energy consumption prediction model for urban planning scenarios with machine learning and Shapley additive explanation methods. *Energy and Buildings*, 287, 112965. https://doi.org/10.1016/j.enbuild.2023.112965.

[11] Singhal, P., Sommer, S., Kaestner, K., & Pahle, M. (2025). Split-incentives in energy efficiency investments? Evidence from rental housing. *Resource and Energy Economics*, 82, 101488. https://doi.org/10.1016/j.reseneeco.2025.101488.